

Sistemas de Recomendação: Relatório do Trabalho Final

Helcio Duarte

Universidade Federal Rural do Rio de Janeiro (UFRRJ)

Nova Iguaçu, RJ, Brasil

Abstract

Este trabalho avalia o desempenho de dois algoritmos de recomendação: Filtragem Colaborativa Baseada em Usuário e SVD Regularizado. Os experimentos foram conduzidos nas bases de dados MovieLens 100k e MovieLens 1M. O estudo inclui o ajuste de hiperparâmetros e a análise de desempenho em cenários de itens populares e raros (long tail), utilizando as métricas RMSE e MAE. Os resultados indicam superioridade do SVD Regularizado em ambos os datasets, especialmente em itens com poucas avaliações.

1 Introdução

O crescimento do volume de dados em plataformas de comércio eletrônico exige sistemas capazes de filtrar informações relevantes. Sistemas de Recomendação (SR) mitigam a sobrecarga de informação, sugerindo itens adequados ao perfil do usuário [1]. Este trabalho implementa e compara duas abordagens de filtragem colaborativa: uma baseada em memória (User-Based CF) e uma baseada em modelo (SVD Regularizado com SGD) [2].

2 Metodologia

2.1 Bases de Dados

Foram utilizados os datasets MovieLens 100k e MovieLens 1M [3]. O MovieLens 100k contém 100.000 avaliações de 943 usuários sobre 1.682 filmes, com esparsidade de 93,7%. O MovieLens 1M contém aproximadamente 1 milhão de avaliações de 6.040 usuários sobre 3.706 filmes.

2.2 Divisão dos Dados

Os dados foram divididos em três conjuntos disjuntos: treino (64%), validação (16%) e teste (20%). A separação em conjunto de validação é fundamental para garantir a validade metodológica: os hiperparâmetros foram selecionados com base exclusivamente no desempenho na validação, e a avaliação final foi realizada uma única vez sobre o conjunto de teste, evitando contaminação entre as etapas de ajuste e avaliação.

2.3 Algoritmos

O **User-Based CF** calcula a similaridade cosseno entre vetores de avaliação dos usuários e prediz a nota de um usuário para um item como a média ponderada das avaliações dos K vizinhos mais similares que avaliaram aquele item. O principal hiperparâmetro é K , o número de vizinhos.

O **SVD Regularizado** fatora a matriz de avaliações em matrizes de fatores latentes P (usuários) e Q (itens), com F fatores. A predição é dada por $\hat{r}_{ui} = \mu + b_u + b_i + P_u \cdot Q_i$, onde μ é a média global e b_u, b_i são termos de bias. O modelo é treinado por Descida de Gradiente Estocástico (SGD) com regularização L2.

2.4 Métricas

As métricas adotadas foram RMSE e MAE. O RMSE penaliza erros maiores de forma quadrática, sendo sensível a predições muito distantes da nota real. O MAE oferece uma medida uniforme do erro médio. A combinação das duas permite uma análise mais completa do comportamento de cada modelo.

2.5 Limitação Computacional no MovieLens 1M

Devido ao custo computacional da predição linha a linha do User-Based CF, a avaliação deste modelo no MovieLens 1M foi realizada sobre uma amostra aleatória de 5.000 exemplos do conjunto de teste e 3.000 exemplos do conjunto de validação. O SVD Regularizado foi treinado e avaliado sobre o conjunto completo. Essa assimetria deve ser considerada na interpretação comparativa dos resultados do dataset 1M.

2.6 Reprodutibilidade

O código-fonte completo dos experimentos está disponível em: <https://github.com/helcioDuarte/recsys-trabalho>

3 Resultados - MovieLens 100k

3.1 Ajuste de Hiperparâmetros

Para o modelo User-Based CF, o valor $K = 30$ apresentou um bom equilíbrio, com RMSE de 1.0155 e MAE de 0.8054 na validação. Como ilustrado na Figura 1(a), valores menores de K aumentaram o erro por instabilidade, e valores maiores trouxeram leve perda de precisão, caracterizando um mínimo claro em $K = 30$.

Para o modelo SVD Regularizado, testaram-se diversos fatores latentes. A Figura 1(b) mostra que a curva decresce de forma suave ao longo de todo o intervalo, sem apresentar um mínimo pronunciado. Embora $F = 200$ tenha apresentado o menor erro na validação (RMSE de 0.9407), o valor escolhido para o modelo final foi $F = 50$ (RMSE de 0.9412). A diferença de desempenho é muito pequena (apenas 0.0005 no RMSE), não justificando o aumento no custo computacional. O modelo final com $F = 50$, taxa de aprendizado $\eta = 0.005$ e regularização $\lambda = 0.02$ obteve, no teste, RMSE de 0.9445 e MAE de 0.7450.

3.2 Benchmarking: Populares vs Raros

Os filmes foram segmentados por popularidade com base no número de avaliações recebidas no treino: o quintil superior (top 20%) foi classificado como popular e o quintil inferior (bottom 20%) como raro. O SVD demonstrou maior robustez na cauda longa (itens raros), com degradação de desempenho menor que o User-Based CF.




Figure 1: Ajuste de hiperparâmetros no MovieLens 100k (conjunto de validação).

Table 1: Desempenho no MovieLens 100k por Cenário

Modelo	Cenário	RMSE	MAE
User-Based CF	Populares	0.9650	0.7653
User-Based CF	Raros	1.5730	1.2393
SVD	Populares	0.9220	0.7260
SVD	Raros	1.1357	0.9202

3.3 Comparação Global

A Figura 2 resume o desempenho final dos dois modelos no conjunto de teste. O SVD Regularizado superou o User-Based CF em ambas as métricas, com RMSE 7,0% menor e MAE 7,5% menor.




Figure 2: Comparação final entre os modelos no MovieLens 100k (teste).

4 Resultados - MovieLens 1M

4.1 Ajuste de Hiperparâmetros

No conjunto de 1 milhão de avaliações, o modelo User-Based CF alcançou seu melhor desempenho na validação (amostra de 3.000 exemplos) com $K = 75$, conforme ilustrado na Figura 3(a). A curva

converge rapidamente e estabiliza a partir de $K = 50$, indicando que vizinhanças maiores não trazem ganhos relevantes. O modelo atingiu no teste final (amostra de 5.000 exemplos) RMSE de 0.9624 e MAE de 0.7686.

O SVD Regularizado obteve a melhor métrica na validação com $F = 100$, como mostrado na Figura 3(b). Diferentemente do 100k, a curva do 1M apresenta queda mais pronunciada e um mínimo bem definido, reflexo do maior volume de dados disponível para o aprendizado dos fatores latentes. Após reteste com 20 épocas sobre o conjunto completo de treino, o modelo alcançou RMSE de 0.8914 e MAE de 0.7042 no conjunto de teste completo.




Figure 3: Ajuste de hiperparâmetros no MovieLens 1M (conjunto de validação).

4.2 Benchmarking: Populares vs Raros

O mesmo critério de segmentação por quintis foi aplicado ao MovieLens 1M. Novamente, o SVD mitigou os impactos da esparsidade de forma mais eficiente. Comparado ao 100k, ambos os modelos apresentaram menor degradação em itens raros no 1M, o que sugere que o maior volume de dados ameniza o problema da cauda longa.

Table 2: Desempenho no MovieLens 1M por Cenário

Modelo	Cenário	RMSE	MAE
User-Based CF	Populares	0.9328	0.7424
User-Based CF	Raros	1.1978	0.9650
SVD	Populares	0.8760	0.6893
SVD	Raros	1.0756	0.8677

4.3 Comparação Global

A Figura 4 resume o desempenho final no MovieLens 1M. O SVD Regularizado manteve sua superioridade, com RMSE 7,4% menor e MAE 8,4% menor em relação ao User-Based CF.




Figure 4: Comparação final entre os modelos no MovieLens 1M (teste).

5 Conclusão

A fatoração de matrizes (SVD Regularizado) superou consistentemente a filtragem colaborativa baseada em usuários em ambos os datasets e em todos os cenários avaliados. A discrepância de desempenho é acentuada em itens raros, comprovando a eficácia

do modelo paramétrico em extrair características latentes mesmo em condições de alta esparsidade. O maior volume de dados do MovieLens 1M beneficiou ambos os modelos, reduzindo o impacto da cauda longa.

Como trabalhos futuros, sugere-se investigar técnicas de mitigação do problema de itens raros, como regularização adaptativa por popularidade ou abordagens híbridas que combinem filtragem colaborativa com informações de conteúdo. Também seria relevante avaliar os modelos sob métricas orientadas à lista de recomendações, como Precision@K e NDCG, que capturam aspectos da qualidade da recomendação não contemplados pelo RMSE e MAE.

References

- [1] G. Adomavicius and A. Tuzhilin. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, 2005.
- [2] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, 2009.
- [3] F. Ricci, L. Rokach, B. Shapira, and P. B. Kantor. *Recommender Systems Handbook*. Springer, 2011.