

# Sistemas de Recomendação: Relatório do Trabalho Final

Helcio Duarte

Universidade Federal Rural do Rio de Janeiro (UFRRJ)

Nova Iguaçu, RJ, Brasil

## Abstract

Este trabalho avalia o desempenho de dois algoritmos de recomendação: Filtragem Colaborativa Baseada em Usuário e SVD Regularizado. Os experimentos foram conduzidos nas bases de dados MovieLens 100k e MovieLens 1M. O estudo inclui o ajuste de hiperparâmetros e a análise de desempenho em cenários de itens populares e raros (long tail), utilizando as métricas RMSE e MAE. Os resultados indicam superioridade do SVD Regularizado em ambos os datasets, especialmente em itens com poucas avaliações.

## 1 Introdução

O crescimento do volume de dados em plataformas de comércio eletrônico exige sistemas capazes de filtrar informações relevantes. Sistemas de Recomendação (SR) mitigam a sobrecarga de informação, sugerindo itens adequados ao perfil do usuário [1]. Este trabalho implementa e compara duas abordagens de filtragem colaborativa: uma baseada em memória (User-Based CF) e uma baseada em modelo (SVD Regularizado com SGD) [2].

## 2 Metodologia

### 2.1 Bases de Dados

Foram utilizados os datasets MovieLens 100k e MovieLens 1M [3]. O MovieLens 100k contém 100.000 avaliações de 943 usuários sobre 1.682 filmes, com esparsidade de 93,7%. O MovieLens 1M contém aproximadamente 1 milhão de avaliações de 6.040 usuários sobre 3.706 filmes.

### 2.2 Divisão dos Dados

Os dados foram divididos em três conjuntos disjuntos: treino (64%), validação (16%) e teste (20%). A separação em conjunto de validação é fundamental para garantir a validade metodológica: os hiperparâmetros foram selecionados com base exclusivamente no desempenho na validação, e a avaliação final foi realizada uma única vez sobre o conjunto de teste, evitando contaminação entre as etapas de ajuste e avaliação.

### 2.3 Algoritmos

O **User-Based CF** calcula a similaridade cosseno entre vetores de avaliação dos usuários e prediz a nota de um usuário para um item como a média ponderada das avaliações dos  $K$  vizinhos mais similares que avaliaram aquele item. O principal hiperparâmetro é  $K$ , o número de vizinhos.

O **SVD Regularizado** fatora a matriz de avaliações em matrizes de fatores latentes  $P$  (usuários) e  $Q$  (itens), com  $F$  fatores. A predição é dada por  $\hat{r}_{ui} = \mu + b_u + b_i + P_u \cdot Q_i$ , onde  $\mu$  é a média global e  $b_u, b_i$  são termos de bias. O modelo é treinado por Descida de Gradiente Estocástico (SGD) com regularização L2.

### 2.4 Métricas

As métricas adotadas foram RMSE e MAE. O RMSE penaliza erros maiores de forma quadrática, sendo sensível a predições muito distantes da nota real. O MAE oferece uma medida uniforme do erro médio. A combinação das duas permite uma análise mais completa do comportamento de cada modelo.

### 2.5 Limitação Computacional no MovieLens 1M

Devido ao custo computacional da predição linha a linha do User-Based CF, a avaliação deste modelo no MovieLens 1M foi realizada sobre uma amostra aleatória de 5.000 exemplos do conjunto de teste e 3.000 exemplos do conjunto de validação. O SVD Regularizado foi treinado e avaliado sobre o conjunto completo. Essa assimetria deve ser considerada na interpretação comparativa dos resultados do dataset 1M.

### 2.6 Reprodutibilidade

O código-fonte completo dos experimentos está disponível em: <https://github.com/helcioDuarte/recsys-trabalho>

## 3 Resultados - MovieLens 100k

### 3.1 Ajuste de Hiperparâmetros

Para o modelo User-Based CF, o valor  $K = 30$  apresentou um bom equilíbrio, com RMSE de 1.0155 e MAE de 0.8054 na validação. Como ilustrado na Figura 1(a), valores menores de  $K$  aumentaram o erro por instabilidade, e valores maiores trouxeram leve perda de precisão, caracterizando um mínimo claro em  $K = 30$ .

Para o modelo SVD Regularizado, testaram-se diversos fatores latentes. A Figura 1(b) mostra que a curva decresce de forma suave ao longo de todo o intervalo, sem apresentar um mínimo pronunciado. Embora  $F = 200$  tenha apresentado o menor erro na validação (RMSE de 0.9407), o valor escolhido para o modelo final foi  $F = 50$  (RMSE de 0.9412). A diferença de desempenho é muito pequena (apenas 0.0005 no RMSE), não justificando o aumento no custo computacional. O modelo final com  $F = 50$ , taxa de aprendizado  $\eta = 0.005$  e regularização  $\lambda = 0.02$  obteve, no teste, RMSE de 0.9445 e MAE de 0.7450.

### 3.2 Benchmarking: Populares vs Raros

Os filmes foram segmentados por popularidade com base no número de avaliações recebidas no treino: o quintil superior (top 20%) foi classificado como popular e o quintil inferior (bottom 20%) como raro. O SVD demonstrou maior robustez na cauda longa (itens raros), com degradação de desempenho menor que o User-Based CF.




Figure 1: Ajuste de hiperparâmetros no MovieLens 100k (conjunto de validação).

Table 1: Desempenho no MovieLens 100k por Cenário

| Modelo        | Cenário   | RMSE   | MAE    |
|---------------|-----------|--------|--------|
| User-Based CF | Populares | 0.9650 | 0.7653 |
| User-Based CF | Raros     | 1.5730 | 1.2393 |
| SVD           | Populares | 0.9220 | 0.7260 |
| SVD           | Raros     | 1.1357 | 0.9202 |

### 3.3 Comparação Global

A Figura 2 resume o desempenho final dos dois modelos no conjunto de teste. O SVD Regularizado superou o User-Based CF em ambas as métricas, com RMSE 7,0% menor e MAE 7,5% menor.




Figure 2: Comparação final entre os modelos no MovieLens 100k (teste).

## 4 Resultados - MovieLens 1M

### 4.1 Ajuste de Hiperparâmetros

No conjunto de 1 milhão de avaliações, o modelo User-Based CF alcançou seu melhor desempenho na validação (amostra de 3.000 exemplos) com  $K = 75$ , conforme ilustrado na Figura 3(a). A curva

converge rapidamente e estabiliza a partir de  $K = 50$ , indicando que vizinhanças maiores não trazem ganhos relevantes. O modelo atingiu no teste final (amostra de 5.000 exemplos) RMSE de 0.9624 e MAE de 0.7686.

O SVD Regularizado obteve a melhor métrica na validação com  $F = 100$ , como mostrado na Figura 3(b). Diferentemente do 100k, a curva do 1M apresenta queda mais pronunciada e um mínimo bem definido, reflexo do maior volume de dados disponível para o aprendizado dos fatores latentes. Após reteste com 20 épocas sobre o conjunto completo de treino, o modelo alcançou RMSE de 0.8914 e MAE de 0.7042 no conjunto de teste completo.




Figure 3: Ajuste de hiperparâmetros no MovieLens 1M (conjunto de validação).

### 4.2 Benchmarking: Populares vs Raros


O mesmo critério de segmentação por quintis foi aplicado ao MovieLens 1M. Novamente, o SVD mitigou os impactos da esparsidade de forma mais eficiente. Comparado ao 100k, ambos os modelos apresentaram menor degradação em itens raros no 1M, o que sugere que o maior volume de dados ameniza o problema da cauda longa.

Table 2: Desempenho no MovieLens 1M por Cenário

| Modelo        | Cenário   | RMSE   | MAE    |
|---------------|-----------|--------|--------|
| User-Based CF | Populares | 0.9328 | 0.7424 |
| User-Based CF | Raros     | 1.1978 | 0.9650 |
| SVD           | Populares | 0.8760 | 0.6893 |
| SVD           | Raros     | 1.0756 | 0.8677 |

### 4.3 Comparação Global

A Figura 4 resume o desempenho final no MovieLens 1M. O SVD Regularizado manteve sua superioridade, com RMSE 7,4% menor e MAE 8,4% menor em relação ao User-Based CF.



**Figure 4: Comparação final entre os modelos no MovieLens 1M (teste).**

## 5 Conclusão

A fatoração de matrizes (SVD Regularizado) superou consistentemente a filtragem colaborativa baseada em usuários em ambos

os datasets e em todos os cenários avaliados. A discrepância de desempenho é acentuada em itens raros, comprovando a eficácia do modelo paramétrico em extrair características latentes mesmo em condições de alta esparsidade. O maior volume de dados do MovieLens 1M beneficiou ambos os modelos, reduzindo o impacto da cauda longa.

## References

- [1] G. Adomavicius and A. Tuzhilin. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, 2005.
- [2] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, 2009.
- [3] F. Ricci, L. Rokach, B. Shapira, and P. B. Kantor. *Recommender Systems Handbook*. Springer, 2011.